ML E IA: DE DESARROLLO A PRODUCCIÓN · S1 A S5

Tu caso: Bank Marketing

Una pregunta, un dato y cuatro avances: de las capas RAW → MASTER → FS → ML hasta un servicio en GCP orquestado con GitHub Actions.

Bank Marketing (UCI) **CC BY 4.0** **41 188 llamadas** **De S1 a S5**

CÓMO USAR ESTAS DIAPOSITIVAS

← → navegan · **O** índice · **F** pantalla completa. La hoja `tu-caso-bank-marketing.md` tiene lo mismo en texto.

Las cifras son recuentos del archivo del repositorio, comprobados con código. **No hay ningún modelo de referencia**: se evalúa tu razonamiento, no que tu métrica sea alta.

EL CASO

Antes de llamar a un cliente: ¿contratará el depósito?

QUÉ PASÓ

- Un **banco portugués** llamó por teléfono a sus clientes para venderles un **depósito a plazo**.
- Las llamadas van de **mayo de 2008 a noviembre de 2010**.
- Cada fila es **una llamada**: no hay identificador de cliente.

LO QUE PREDICES

La columna `y` : **sí** o **no**. Solo puedes usar lo que se sabe **antes** de que el cliente conteste.

41 188
llamadas (filas)

11,27 %
dijeron que sí (4 640 llamadas)

20 + 1
variables, más el objetivo `y`

Fuente: Moro, Rita y Cortez (2014), *Bank Marketing*, UCI Machine Learning Repository, licencia CC BY 4.0 (citarla es obligatorio). doi:10.24432/C5K306

LO QUE SE REPITE Y LO QUE CAMBIA

Misma receta que el docente, otro dato

RAW el dato tal cual → **MASTER** limpio y ordenado → **FS** variables conocidas antes → **ML** objetivo y partición → **Entrenamiento** modelos y MLflow

	CASO DEL DOCENTE: ONLINE RETAIL II	TU CASO: BANK MARKETING
Pregunta	¿Volverá el cliente a comprar en los 90 días siguientes?	Antes de llamar, ¿contratará el depósito?
Una fila es	un cliente en una fecha de corte	una llamada (sin cliente identificable)
Tiempo	fecha de corte explícita	solo mes y día de la semana; el archivo va ordenado por fecha
Partición	temporal, por fecha de corte	aleatoria estratificada en S1 a S4; por orden de filas en S5
La trampa	usar datos posteriores al corte	`duration` : se conoce al terminar la llamada
Suciedad	duplicados, cancelaciones, códigos que no son productos	`unknown` , filas idénticas, `pdays` = 999

EL DATO

Dónde está y cómo leerlo

TERMINAL · DESDE LA RAÍZ DEL REPOSITORIO, CON EL ENTORNO ENV-IA-MLOPS

```
> python -c "import pandas as pd; d = pd.read_csv('02-Proyecto-Transversal/datos/bank-marketing/bank-additional-full.csv', sep=';'); print(d.shape); print(d['y'].value_counts().to_dict())"
```

```
> cd 02-Proyecto-Transversal/datos
```

```
> sha256sum -c SHA256SUMS
```

DEBE SALIR

```
(41188, 21)
{'no': 36548, 'yes': 4640}
```

Salida real del primer comando, medida al preparar S0 (Linux). El tercero debe decir **OK** en cada línea.

NO HAGAS ESTO

- Abrirlo y guardarlo con **Excel**: cambia el archivo.
- **Reordenar las filas**: el orden es la única información temporal (y la necesitas en S5).
- Editarlo a mano: todo cambio, con código y sobre tu capa RAW.
- No leer `bank-additional-names.txt`: es la documentación del autor.

VEINTE VARIABLES Y UN OBJETIVO

Las variables, en cuatro grupos

DEL CLIENTE · 7

`age` edad · `job` trabajo · `marital` estado civil
`education` estudios · `default` crédito en mora
`housing` crédito de vivienda · `loan` préstamo personal

DEL ÚLTIMO CONTACTO · 4

`contact` móvil o fijo · `month` mes · `day_of_week` día de la semana
~~`duration`~~ duración de la llamada: **fuera del modelo**

DE CAMPAÑAS ANTERIORES Y DE ESTA · 4

`campaign` contactos de esta campaña (**incluye la llamada actual**)
`pdays` días desde el último contacto anterior (999 es un código)
`previous` contactos anteriores · `poutcome` resultado de la campaña anterior

CONTEXTO ECONÓMICO · 5

`emp.var.rate` empleo · `cons.price.idx` precios · `cons.conf.idx` confianza
`euribor3m` euríbor a 3 meses · `nr.employed` empleados

Indicadores del país (Banco de Portugal), no del cliente: trimestrales, mensuales y diarios.

Objetivo: `y` · `yes` si contrató el depósito, `no` si no. Hay 4 640 síes y 36 548 noes.

LA MÁS IMPORTANTE

`duration`: solo se conoce cuando la llamada termina

Antes de llamar
sabes todo lo demás: cliente, campañas, contexto

→

Llamas
ocurre la conversación

→

`duration`
solo existe aquí: cuántos segundos duró

→

`y`
sí o no

POR QUÉ QUEDA FUERA

- Una llamada larga suele ser una que **acaba bien**: usarla es darle al modelo lo que debe adivinar.
- El autor lo advierte en `bank-additional-names.txt`: con duración 0 la respuesta es «no» (4 filas de este archivo lo cumplen) y recomienda descartarla en un modelo realista.

QUÉ HACES

- Déjala **fuera de FS y de ML**.
- Escribe una **prueba que falle** si `duration` (o cualquier columna que no se conozca antes de llamar) vuelve a entrar.
- Si tu AUC te parece demasiado bueno, **sospecha de una fuga** antes de celebrarlo.

Lo que tendrás que decidir al limpiar

QUÉ ENCUENTRAS	CIFRA EN EL ARCHIVO	TU DECISIÓN
`unknown` en seis columnas	`job` 330 · `marital` 80 · `education` 1 731 · `default` 8 597 · `housing` 990 · `loan` 990	¿Valor perdido, categoría o descartar filas?
Filas idénticas	12 pares, iguales en las 21 columnas	Sin cliente no sabes si es la misma llamada. ¿Se descartan?
`pdays` = 999	39 673 filas; en 4 110 de ellas `previous` > 0	Es un código, no días. ¿Cómo lo representas?
`poutcome` y `previous`	`nonexistent` (35 563) son justo las filas con `previous` = 0	Dicen lo mismo: ¿conservas las dos?
Nombres con punto	`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `nr.employed`	Renómbralas con una convención y anótala

Lo que descartes no desaparece: queda en una tabla de descartes con su motivo, para que **raw = master + descartes**.

LA CAPA FS EN ESTE CASO

FS: lo que se sabe antes de marcar el número

Sin identificador de cliente no hay historial por cliente: FS es **una fila por llamada**, con las variables conocidas antes de llamar, y un **catálogo** que explica por qué se conocen.

VARIABLES	¿SE CONOCE ANTES DE LLAMAR?	QUÉ DECIDES
Del cliente (7)	SÍ	qué haces con `unknown`
`contact`, `month`, `day_of_week`	SÍ	se planifican con la llamada; cómo codificas `month`, que no trae año
`campaign`	DEPENDE	cuenta la llamada actual: úsala solo si puedes justificarlo
`pdays`, `previous`, `poutcome`	SÍ	vienen de campañas anteriores; el 999
Contexto económico (5)	DEPENDE	¿estaba publicado el valor el día de la llamada?
`duration`	NO	fuera, con una prueba que lo vigila

CÓMO SE REPARTEN LOS DATOS

La partición: aleatoria ahora, por orden de filas en S5

■ entrenamiento · ■ validación · ■ prueba · ilustración, no son datos

S1 A S4 · ALEATORIA Y ESTRATIFICADA



- La misma **proporción de síes** en entrenamiento, validación y prueba.
- Semilla fija y **guardada**.
- Es **optimista**, y lo dejas escrito: probablemente porque las llamadas de una misma época se parecen y quedan repartidas entre entrenamiento y prueba.

S5 · EL MISMO MODELO, POR ORDEN DE FILAS



- Las **primeras filas** entrenan y las **últimas** prueban: el orden del archivo es el del tiempo.
- Compara con lo anterior y **explica la diferencia**; empieza mirando la proporción de síes en cada tramo.
- Por eso no puedes reordenar el archivo.

QUÉ SE ENTREGA Y CUÁNDO

Cuatro avances y una entrega final

AVANCE	TRABAJAS EN	PRESENTAS EN	ENTREGA, A MÁS TARDAR	QUÉ LLEVA
1	S1 y trabajo autónomo	S2	mié 18 nov, 10:00	Capas RAW → MASTER → FS → ML, entrenamiento y métricas, **como cuadernos**
2	S2 y trabajo autónomo	S3	vie 20 nov, 10:00	El pipeline **ya en Python**, API, contenedor y pruebas. La Ruta B de la tarea de S2 es este avance
3	S3 y trabajo autónomo	S4	mié 25 nov, 10:00	Migración a GCP y despliegue: inventario, datos migrados y validados, servicio y registros
4	S4 y trabajo autónomo	S5	vie 27 nov, 10:00	Pipeline orquestado con GitHub Actions: workflow funcionando, historial y una decisión explicada
Final	tras S5	por definir	vie 11 dic, 10:00	Repositorio, informe y demostración, con la evaluación por orden de filas de S5

Sesiones los miércoles y viernes, de 10:00 a 14:00 (hora de Perú). Cada avance se presenta en la **sesión siguiente** y se entrega antes de que empiece. Entre S2 y S3 y entre S4 y S5 solo hay dos días. Se entrega con el **formulario de Google del curso**: el instructor da el enlace en clase. Las tareas de cada sesión son un ejercicio aparte, salvo la Ruta B de S2.

Qué lleva cada avance y cómo se evalúa

CADA AVANCE PRESENTA

- El **resultado**: qué funciona y qué no.
- Cómo se **ejecuta**, en orden y con versiones.
- Las **pruebas**, y que fallan si se rompe la regla.
- **Una decisión**, con evidencia.
- Las **dificultades** y lo que no pudiste ejecutar.
- Los **pasos** para que otra persona lo reproduzca.

Se entrega con `plantilla-avance.md`.

RÚBRICA · 100 PUNTOS

CRITERIO	PESO
Reproducibilidad	20
Técnica	40
Análisis y decisión	40

Ver `rubrica-avance.md`. No hay modelo de referencia: una decisión de «no» bien argumentada vale tanto como una de «sí».

ALERTAS QUE LIMITAN LA NOTA

- `duration` (o algo que no se conoce antes de llamar) en el modelo: la **técnica** no supera 15.
- Solo capturas, sin código ni pruebas ejecutables: la **reproducibilidad** no supera 8.
- Sin citar la fuente del dato: la **reproducibilidad** no supera 15.

Listo para S1

- [ ] La huella de mi copia del CSV es correcta (`sha256sum -c SHA256SUMS`). — Dónde está
- [ ] El comando de lectura imprime `(41188, 21)` y el recuento de síes. — Dónde está
- [ ] He leído `bank-additional-names.txt` entera. — Dónde está
- [ ] Puedo explicar por qué `duration` queda fuera. — La trampa
- [ ] Sé qué decisiones son mías: `unknown` , filas idénticas, `pdays` , `campaign` e indicadores. — MASTER y FS
- [ ] Sé qué se entrega en cada avance y que no hay un modelo de referencia. — Los avances

Las marcas se guardan solo en este navegador.

Siguiente: la hoja `02-Proyecto-Transversal/alumno/tu-caso-bank-marketing.md` , con lo mismo en texto y las decisiones una por una.