Laboratorio S1 · 135 minutos

Se trabaja dentro de `04-Proyecto-Base/` con el entorno `env-ia-mlops` (terminal: **Anaconda Prompt** o la terminal de VS Code con el entorno activado). Los comandos valen en CMD y PowerShell. `make` no existe en Windows: se usan las líneas equivalentes.

Min	Bloque
0–10	0. Preparar
10–40	1. Cuaderno 01: RAW → MASTER
40–65	2. Cuaderno 02: MASTER → FS
65–75	**Pausa**
75–100	3. Cuaderno 03: FS → ML
100–125	4. Cuaderno 04: entrenar y MLflow
125–135	5. Traducir a `.py` y probar

Los números que verás con la **muestra** (23 070 filas) son distintos de los del dato completo de las diapositivas. Es esperado.

0. Preparar (10 min)

```
conda activate env-ia-mlops
cd 04-Proyecto-Base
python -m pytest -q -m "not lento"
```

Esperado: `30 passed` (las 4 pruebas restantes ejecutan los cuadernos y son lentas). En VS Code abre cada `.ipynb` y elige el kernel **env-ia-mlops**.

1. Cuaderno 01 · RAW → MASTER (30 min)

Abre `notebooks/01_pipeline_raw_a_master.ipynb` y ejecuta celda a celda (parámetro `FUENTE = 'muestra'`). **Mira:**

- La carga a RAW: 23 070 filas con `_id`, `_hoja`, `_fila`.
- `master_descartes`: cuántas filas y con qué motivo.
- La conciliación: `raw = master_lineas + descartes`.
- `master_calidad`: las 13 reglas deben estar en `OK`.

Preguntas: ¿cuántas líneas no tienen cliente? ¿Por qué no se descartan? **Comprobación:** `SELECT COUNT(*) FROM raw_online_retail_ii;` da 23 070 en el visor SQLite.

2. Cuaderno 02 · MASTER → FS (25 min)

Ejecuta `notebooks/02_pipeline_master_a_fs.ipynb`. **Mira:** `fs_catalogo` (13 variables), una fila de `fs_cliente_corte` y el recálculo manual con pandas del cliente de ejemplo. **Haz:** cambia el corte de ejemplo a otra fecha y comprueba que la recencia cambia como esperas. **Prueba definitiva** (terminal):

```
python -m pytest tests -k futuro -q
```

Esperado: `2 passed` (todas las pruebas cuyo nombre contiene «futuro»). Esta prueba borra todo lo posterior al corte y comprueba que las variables no cambian.

Pausa (10 min)

3. Cuaderno 03 · FS → ML (25 min)

Ejecuta `notebooks/03_pipeline_fs_a_ml.ipynb`. **Mira:** `ml_particiones` (ventanas que no se solapan), el número de filas y la tasa de recompra por partición (con la muestra: train 626 filas · 50,8 %, valid 114 · 45,6 %, test 250 · 40,4 %). **Pregunta:** ¿por qué la tasa baja de train a test? ¿Qué implicaría para un modelo en producción?

4. Cuaderno 04 · Entrenar y MLflow (25 min)

Ejecuta `notebooks/04_entrenamiento_y_seguimiento.ipynb`. **Mira:** la referencia (AUC 0,5), regresión logística y gradient boosting (con la muestra: regresión logística valid 0,698 · test 0,747; gradient boosting 0,663 · 0,735). Después, desde una terminal en `04-Proyecto-Base`:

```
mlflow ui --backend-store-uri sqlite:///models/mlflow.db
```

Abre http://127.0.0.1:5000, entra al experimento `retencion-90d`, selecciona **dos ejecuciones** y pulsa *Compare*. **Anota:** la huella del dato (`huella_datos`) de ambas. ¿Coincide? Solo entonces la comparación es válida.

5. Traducir a `.py` y probar (10 min)

```
python -m ia_mlops.pipeline
jupytext --to py:percent notebooks/01_pipeline_raw_a_master.ipynb -o
scripts_desde_notebooks/01_pipeline_raw_a_master.py
python -m pytest tests/test_notebooks.py -q
```

(`jupytext` se convierte un cuaderno a la vez; repite con los otros tres si hay tiempo. La prueba de equivalencia puede tardar unos minutos.) **Pregunta:** ¿qué demuestra la prueba de equivalencia?

Si algo falla

Síntoma	Qué hacer
`ModuleNotFoundError` en un cuaderno	Kernel equivocado: selecciona `env-ia-mlops`.

Síntoma	Qué hacer
El 02 falla al leer tablas	Ejecuta primero el 01 completo.
`mlflow ui` no abre	Revisa que estés en `04-Proyecto-Base` y que exista `models/mlflow.db` (lo crea el cuaderno 04).
La prueba de equivalencia falla	Anota el mensaje en las evidencias; no lo ocultes.

Para quien termina antes

Empieza la tarea: `../tarea/README.md`.