Proyecto base: retención de clientes con Online Retail II

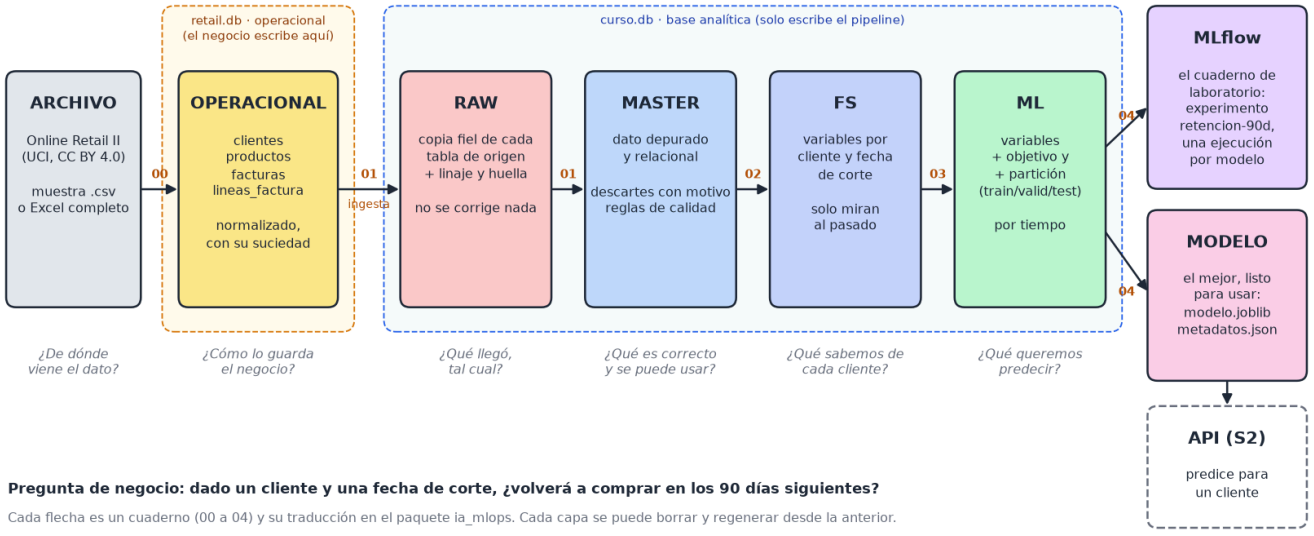
> Proyecto Python con la estructura de **Cookiecutter Data Science**. Los **cuadernos** son los pipelines; el paquete `ia_mlops` es su traducción a `.py`, la que se empaqueta, se prueba y se despliega. **S2** añade la API (`ia_mlops/api/`) y la imagen Docker.

Pregunta de negocio: dado un cliente y una fecha de corte, ¿volverá a comprar en los **90 días siguientes**?
Dato: Online Retail II (UCI, licencia CC BY 4.0), 1 067 371 líneas de una tienda online, 2009–2011. Ver `docs/modelo-de-datos.md` y `references/fuente.md`.

Las capas, en este orden

```
OPERACIONAL (retail.db)  →  RAW  →  MASTER  →  FS  →  ML  →  ARTEFACTOS  →  SERVICIO (S2)
```

Del dato del negocio al modelo en producción: qué construye cada cuaderno



El dato nace en una **base operacional** simulada (`data/external/retail.db`, el sistema de ventas de la tienda) y el pipeline lo **ingiere** en la base analítica (`data/processed/curso.db`). **FS va antes que ML:** ML se construye a partir de las variables de FS, más el objetivo y la partición.

Capa	Cuaderno (el pipeline)	Pipeline `.py` (se ejecuta solo)	Lógica (módulos)	SQL
OPERACIONAL (simulación)	`00_pipeline_operacional`	`python -m ia_mlops.operacional`	`operacional.py`	`sql/operacional/`
RAW	`01_pipeline_raw_a_master` (1)	`python -m ia_mlops.pipeline_ingesta_raw`	`dataset.py`	`sql/raw/`

Capa	Cuaderno (el pipeline)	Pipeline `.py` (se ejecuta solo)	Lógica (módulos)	SQL
MASTER	`01_pipeline_raw_a_master` (2–4)	`python -m ia_mlops.pipeline_ingesta_master`	`dataset.py`, `calidad.py`	`sql/master/`
FS y ML	`02_pipeline_master_a_fs` y `03_pipeline_fs_a_ml`	`python -m ia_mlops.pipeline_ml`	`features.py`, `modeling/ml_dataset.py`	`sql/fs/`, `sql/ml/`
Entrenamiento y MLflow	`04_entrenamiento_y_seguimiento`	`python -m ia_mlops.pipeline_train`	`modeling/train.py`	
Predicción (base de la API)			`modeling/predict.py`	
Servicio (S2)		`make api`	`ia_mlops/api/`	

Los cuatro pipelines son independientes e idempotentes (`ia_mlops/control.py`). Cada uno comprueba que su entrada existe (si no, dice qué ejecutar antes) y calcula una **huella de entrada** (datos que lee + su código + la configuración). Si coincide con la de su última ejecución correcta, **no hace nada**; si cambió, reconstruye su capa desde cero. `--forzar` lo rehace siempre. Repetirlos no duplica nada, ni siquiera ejecuciones en MLflow. `python -m ia_mlops.pipeline` solo los lanza en orden, por comodidad; en S4 los lanzará GitHub Actions.

Estructura (Cookiecutter Data Science)

```
04-Proyecto-Base/
├── README.md · Makefile · pyproject.toml
├── data/
│   ├── raw/            muestra_online_retail_ii.csv (en el repo) y online_retail_ii/ (el
original, se descarga)
│   ├── external/       retail.db: la base operacional simulada (se genera)   interim/   pasos
intermedios
│   └── processed/      curso.db: la base analítica con las capas RAW a ML (se genera)
├── docs/               modelo-de-datos.md · de-notebook-a-python.md · api-y-contenedor.md · img/
(diagramas)
├── models/             modelo.joblib · modelo_mlflow/ · metadatos.json · mlflow.db (se generan)
├── notebooks/          los cinco cuadernos-pipeline (00 a 04)
├── references/         fuente del dato y licencia
├── reports/            metricas.json y figures/ (se generan)
├── sql/                esquemas (DDL) y scripts de inserción de cada capa
├── ia_mlops/           el paquete Python
│   ├── config.py · db.py · control.py · operacional.py · dataset.py · calidad.py · features.py
│   ├── pipeline_ingesta_raw.py · pipeline_ingesta_master.py · pipeline_ml.py · pipeline_train.py
· pipeline.py (orquestador)
│   ├── modeling/       ml_dataset.py · train.py · predict.py · comparar.py (S2: compara los
caminos hacia el modelo)
│   └── api/            la API de S2: esquemas.py (contrato) · servicio.py (modelo) · app.py
(FastAPI) · registro.py (logs)
├── deploy/             docker/Dockerfile · github-actions/ci.yml (S2) · cloud-run y kubernetes
(S3 y S4)
├── requirements-api.txt · requirements-api.lock · requirements-dev.txt     lo que instala la
imagen y lo que instala el CI
├── .dockerignore · .devcontainer/     qué deja fuera la imagen · Codespace con Python 3.11 y
Docker (sin probar)
└── tests/              equivalencia cuaderno = paquete, idempotencia de los pipelines, API e
imagen
```

Empezar (con el entorno `env-ia-mlops` activo, desde esta carpeta)

```
pip install -e .                                  # instala ia_mlops en modo editable (una vez)
python -m ia_mlops.operacional                    # simula la base de ventas retail.db con la
muestra (una vez)
python -m ia_mlops.pipeline                       # los cuatro pipelines en orden (segundos)
python -m ia_mlops.pipeline                       # otra vez: «sin cambios» en los cuatro
python -m ia_mlops.pipeline_train --forzar        # uno solo, forzado
```

Los **cuadernos** (el camino de S1): ábrelos en VS Code con el kernel `env-ia-mlops` y ejecútalos **en orden, del 00 al 04**. El 00 explica todo el recorrido. Desde la terminal:

```
papermill notebooks/00_pipeline_operacional.ipynb salida00.ipynb -p FUENTE muestra
papermill notebooks/01_pipeline_raw_a_master.ipynb salida01.ipynb
```

Con el dato **completo** (1,07 millones de filas, unos 2 minutos):

```
python -m ia_mlops.dataset descargar              # baja el Excel de UCI y verifica su huella
sha256
python -m ia_mlops.operacional --fuente completo  # el operacional cambia...
python -m ia_mlops.pipeline                       # ...y los pipelines lo detectan y rehacen todo
```

`make` hace lo mismo con atajos (`make operacional`, `make pipeline`, `make raw`, `make master`, `make ml`, `make train`, `make notebooks`, `make test`, `make traducir`, y desde S2 `make api`, `make comparar`, `make imagen`, `make contenedor`, `make lock`). En Windows no hay `make`: ejecuta las líneas `python` y `papermill` del `Makefile`.

De cuaderno a Python

Dos caminos, y las pruebas exigen que den **el mismo resultado**: ver `docs/de-notebook-a-python.md`.

1. **Traducción literal** con jupytext: `make traducir` deja un `.py` por cuaderno en `scripts_desde_notebooks/`.
2. **Refactorización** a funciones con nombre, rutas configurables y registro: es el paquete `ia_mlops`.

La API y la imagen (S2)

```
python -m ia_mlops.pipeline                # deja models/modelo_mlflow/ y models/metadatos.json
make api                                   # http://127.0.0.1:8080/docs
curl http://127.0.0.1:8080/predecir ...    # ver docs/api-y-contenedor.md
docker build -f deploy/docker/Dockerfile -t retencion-api:local .      # en Codespaces
```

Cinco endpoints (`/salud`, `/listo`, `/modelo`, `/predecir`, `/predecir/lote`), un contrato que sale de la **firma del modelo MLflow**, errores 422/503/500 distinguibles, registros JSON por la salida estándar y una imagen mínima que no corre como root. Todo explicado, con lo que se probó y lo que no, en `docs/api-y-contenedor.md`.

Pruebas

```
python -m pytest tests                  # todas (incluye ejecutar los cuadernos)
python -m pytest tests -m "not lento"   # sin ejecutar los cuadernos
```

Comprueban, entre otras cosas: que el operacional reconstruye cada fila del archivo, que RAW es copia exacta del operacional, que `raw = master + descartes`, la integridad referencial, que **FS no usa información del futuro**, que la partición es temporal y sus ventanas no se solapan, que el objetivo se recalcula igual con pandas, que los cuadernos y el paquete producen **las mismas tablas y las mismas métricas**, y que los cuadernos traducidos a `.py` con jupytext también. Desde S2: que la API devuelve **la misma probabilidad** que el paquete, el `joblib` y el modelo MLflow, que su esquema coincide con la firma del modelo, que rechaza lo imposible y avisa de lo no visto, que no filtra detalles internos en un 500 ni datos de clientes en los logs, y que la imagen contiene solo lo necesario.

Resultados con el dato completo

Modelo	AUC en test	Aciertos entre el 10 % con más probabilidad
Referencia sin aprender (tasa base 38 %)	0,500	34 %
Regresión logística	**0,796**	**90 %**
Gradient boosting	0,781	88 %

La tasa de recompra cambia entre periodos (48 % en train, 35 % en valid, 38 % en test): es el punto de partida para hablar de **deriva** en S5. Las cifras salen de `reports/metricas.json` tras ejecutar el pipeline completo.

Estado

S1 usa los cinco cuadernos y los cuatro pipelines. **S2** (esta versión) añade la API y el Dockerfile. S3 migra el caso a GCP y despliega esta misma imagen en Cloud Run (`deploy/cloud-run`; Kubernetes, en `deploy/kubernetes`, como laboratorio en Codespaces); S4 orquesta la construcción, publicación y despliegue con GitHub Actions (y los pipelines, cada uno como un paso); S5 añade versionado de modelos con alias, deriva, monitoreo y rollback.