Tu caso: Bank Marketing

Es el caso que desarrollas tú **de S1 a S5**, con la misma receta que el docente usa con Online Retail II: **RAW → MASTER → FS → ML → entrenamiento**, y después API, contenedor, GCP y workflow. Esta hoja dice qué dato tienes, qué decisiones son tuyas y qué se entrega. Léela entera antes de S1. La presentación «Tu caso de S1 a S5» resume lo mismo en 12 diapositivas.

> **Aquí no hay un modelo de referencia que alcanzar.** Lo que se evalúa es tu razonamiento, tus pruebas y que otra persona pueda repetir tu trabajo (ver `rubrica-avance.md`).

1. La pregunta

Un banco portugués llamó por teléfono a sus clientes para venderles un **depósito a plazo**, de mayo de 2008 a noviembre de 2010.

> **Antes de llamar a un cliente, ¿contratará el depósito a plazo?**

- Cada fila es **una llamada**. No hay identificador de cliente: no puedes agrupar por cliente ni saber si dos filas son la misma persona.
- El objetivo es la columna `y`: `yes` (contrató) o `no`.
- Solo puedes usar lo que se sabe **antes** de que el cliente conteste. Por eso `duration` **(la duración de la llamada) queda fuera del modelo**: ver el apartado 5.

2. El dato

- Archivo: `02-Proyecto-Transversal/datos/bank-marketing/bank-additional-full.csv` (separador `;`).
- Documentación del autor: `02-Proyecto-Transversal/datos/bank-marketing/bank-additional-names.txt`. **Léela entera.**
- Licencia **CC BY 4.0**: puedes usarlo citando la fuente (apartado 9).

Desde la raíz del repositorio, con el entorno `env-ia-mlops` activo, este comando lee el archivo:

```
python -c "import pandas as pd; d = pd.read_csv('02-Proyecto-Transversal/datos/bank-marketing/bank-additional-full.csv', sep=';'); print(d.shape);
print(d['y'].value_counts().to_dict())"
```

Debe imprimir:

```
(41188, 21)
{'no': 36548, 'yes': 4640}
```

Para comprobar que tu copia es la original (desde la carpeta `02-Proyecto-Transversal/datos`; en PowerShell, `Get-FileHash -Algorithm SHA256 bank-marketing\bank-additional-full.csv` y compara con la línea de `SHA256SUMS`):

```
sha256sum -c SHA256SUMS
```

No hagas esto:

- Abrirlo y guardarlo con Excel: cambia el archivo.
- Reordenar las filas: **el orden del archivo es la única información temporal** que tienes (está ordenado por fecha) y la necesitarás en S5.
- Editarlo a mano. Todo cambio se hace con código, sobre la copia de tu capa RAW.

3. Cifras para comprobar tu carga

Medidas sobre el archivo del repositorio. Si tu RAW o tu MASTER no cuadran con ellas, algo falló en tu carga o en tu limpieza.

Qué	Valor
Filas · columnas	41 188 · 21 (20 variables + `y`)
`y` = `yes`	4 640 (11,27 %)
`y` = `no`	36 548
Filas idénticas a otra (en las 21 columnas)	12 pares
Valores `unknown`	`job` 330 · `marital` 80 · `education` 1 731 · `default` 8 597 · `housing` 990 · `loan` 990
`pdays` = 999	39 673 filas
`previous` > 0 y `pdays` = 999 a la vez	4 110 filas
`poutcome` = `nonexistent`	35 563 filas (son exactamente las de `previous` = 0)
Meses presentes	todos menos enero y febrero; no hay año ni fecha en ninguna columna

Con un 11,27 % de síes, un modelo que **siempre** dijera «no» acertaría el 88,73 % de las veces. Por eso se mira el AUC y la precisión media, no solo la exactitud.

4. Las variables, en cuatro grupos

La clasificación es la del autor. **Ojo** señala lo que tendrás que decidir.

Del cliente (7)

- `age`: edad. **Ojo:** en este archivo va de 17 a 98.
- `job`: tipo de trabajo (12 categorías). **Ojo:** tiene `unknown`.
- `marital`: estado civil. **Ojo:** `divorced` incluye viudos, según el autor; tiene `unknown`.
- `education`: nivel de estudios (8 categorías). **Ojo:** tiene `unknown`.
- `default`: ¿tiene crédito en mora? **Ojo:** solo 3 `yes`; 8 597 `unknown`.
- `housing`: ¿tiene crédito de vivienda? **Ojo:** tiene `unknown`.
- `loan`: ¿tiene préstamo personal? **Ojo:** tiene `unknown`.

Del último contacto (4)

- `contact`: tipo de contacto, `cellular` o `telephone`.
- `month`: mes del último contacto. **Ojo:** sin año.
- `day_of_week`: día de la semana (lunes a viernes).
- `duration`: duración de la llamada, en segundos. **Ojo: queda fuera del modelo.**

De campañas anteriores y de esta (4)

- `campaign`: contactos de esta campaña con este cliente. **Ojo:** incluye la llamada actual.
- `pdays`: días desde el último contacto de una campaña anterior. **Ojo:** 999 es un código, no días.
- `previous`: contactos antes de esta campaña.
- `poutcome`: resultado de la campaña anterior: `failure`, `nonexistent` o `success`.

Contexto económico (5) (indicadores del país publicados por el Banco de Portugal; no son del cliente)

- `emp.var.rate`: variación del empleo (trimestral).
- `cons.price.idx`: índice de precios al consumo (mensual).
- `cons.conf.idx`: índice de confianza del consumidor (mensual).
- `euribor3m`: euríbor a 3 meses (diaria).
- `nr.employed`: número de empleados (trimestral).

Objetivo: `y`.

5. La trampa: `duration`

`duration` es la duración de la llamada. **Solo se conoce cuando la llamada termina**, y una llamada larga suele ser una llamada que acaba bien: usarla es decirle al modelo lo que quieres que adivine. El propio autor lo advierte en `bank-additional-names.txt`: si la duración es 0, la respuesta es «no» (pasa en 4 filas de este archivo), y recomienda descartarla en un modelo realista.

Qué haces:

1. Déjala **fuera de FS y de ML**.
2. Escribe una **prueba** que falle si `duration` (o cualquier columna que no se conozca antes de llamar) vuelve a entrar en las variables del modelo. Es tu equivalente de la prueba «no futuro» del caso del docente.
3. Si algún día tu AUC te parece demasiado bueno, **sospecha de una fuga** antes de celebrarlo.

6. Decisiones que son tuyas

En cada una, deja escrito en tu avance qué hiciste, **por qué** y qué efecto tuvo (cuántas filas, cuánto cambian las métricas si lo pruebas).

Decisión	Lo que hay en el archivo	Preguntas
`unknown`	seis columnas (apartado 3)	¿Lo tratas como valor perdido, como una categoría más o descartas filas? ¿Es lo mismo en `default` (8 597) que en `marital` (80)?

Decisión	Lo que hay en el archivo	Preguntas
Filas idénticas	12 pares, iguales en las 21 columnas (también en `duration`)	Sin identificador de cliente no se sabe si es la misma llamada repetida o dos llamadas distintas con los mismos valores. ¿Qué haces? Lo descartado debe quedar en una tabla de descartes, con su motivo, para que `raw = master + descartes`.
`pdays` **= 999 y** `previous`	4 110 filas con `previous` > 0 y `pdays` = 999, aunque la documentación dice que 999 es «no contactado antes»	Un 999 tratado como días es un valor enorme que no significa lo que parece. ¿Cómo lo representas (por ejemplo, una variable «fue contactado antes» y los días solo cuando existen)? ¿Qué haces con esas 4 110 filas?
`campaign`	cuenta **incluida** la llamada actual	¿Lo conoces antes de marcar el número? Si la usas, explica en qué sentido.
Indicadores económicos	trimestrales, mensuales y diarios	¿Estaba publicado el valor cuando se hizo la llamada? ¿Qué pasa con ellos al partir los datos?
`month` **y** `day_of_week`	sin año ni fecha	¿Cómo los codificas? Con el año ausente, `month` mezcla campañas de años distintos.

7. Cómo se traduce a las capas

Parte de la estructura de `04-Proyecto-Base/` (mismas carpetas: `sql/`, `notebooks/`, paquete Python, `tests/`, `models/`, `reports/`; ver su `docs/modelo-de-datos.md`). Los nombres de tablas de la columna central son orientativos: si cambias alguno, sé coherente en todo el proyecto. Si copias `04-Proyecto-Base/` para empezar, cambia el nombre del paquete: dos proyectos con el mismo paquete en el mismo entorno pueden confundirse (sin probar).

Capa	Qué haces con Bank Marketing	Tablas (orientativas)	Qué compruebas
RAW	Cargas el CSV **tal cual**, sin limpiar, con el **número de fila original** y la huella del archivo	`raw_llamadas`, `raw_carga`	41 188 filas; 4 640 síes
MASTER	Tipos correctos, nombres de columna sin puntos (`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `nr.employed`), tus decisiones sobre `unknown`, duplicados y `pdays`; reglas de calidad	`master_llamadas`, `master_descartes`, `master_calidad`	`raw = master + descartes`; categorías dentro de lo que dice la documentación
FS	Una fila por llamada con las variables **conocidas antes de llamar**, y su catálogo (descripción, fórmula, unidad y por qué se conoce antes)	`fs_llamada`, `fs_catalogo`	`duration` no está; la prueba lo vigila
ML	Objetivo (`y` a 1 y 0) y partición aleatoria estratificada, con semilla, guardada en una tabla	`ml_dataset`, `ml_particiones`	proporción de síes parecida en las tres particiones
Entrenamiento	Los tres modelos del caso del docente (referencia sin aprender, regresión logística y *gradient boosting*), con AUC y precisión media en validación y prueba, registrados en MLflow	`models/`, `reports/`	dos ejecuciones comparables; la elección se hace con validación

La **huella** de cada capa (cuántas filas y de dónde vienen) es lo que te permite decir «este modelo se entrenó con estos datos».

8. La partición

- **De S1 a S4: aleatoria y estratificada.** La misma proporción de síes en entrenamiento, validación y prueba, con una semilla fija y guardada. **Es optimista, y debes dejarlo escrito**: probablemente, porque las llamadas de una misma época se parecen y quedan repartidas entre entrenamiento y prueba.
- **En S5: el mismo modelo, evaluado por orden de filas** (las primeras para entrenar, las últimas para probar). Compara con lo anterior y explica la diferencia; empieza por mirar qué proporción de síes hay en cada tramo. No hace falta antes: si lo pruebas por tu cuenta, anótalo como exploración.

9. Qué se entrega y cuándo

Cada avance se presenta en la **sesión siguiente** a aquella en la que se trabaja. Las fechas las fija el instructor y **aún no están definidas**.

Avance	Se trabaja en	Se presenta en	Qué lleva
1	S1 y trabajo autónomo	S2	Capas RAW → MASTER → FS → ML, entrenamiento y métricas, **como cuadernos**
2	S2 y trabajo autónomo	S3	El pipeline **ya en Python** (la traducción de los cuadernos), API, contenedor y pruebas. **La Ruta B de la tarea de S2 es este avance**
3	S3 y trabajo autónomo	S4	Migración a GCP y despliegue: inventario, datos migrados y validados, servicio desplegado y registros. Opcional: módulo neuronal
4	S4 y trabajo autónomo	S5	Pipeline orquestado con GitHub Actions: workflow funcionando, historial de ejecuciones y una decisión explicada
Final	tras S5	por definir	Repositorio, informe y demostración, con la evaluación por orden de filas de S5

Las tareas de cada sesión (por ejemplo, la de S1: añadir una variable al caso Online Retail II) son un ejercicio aparte de estos avances, salvo la Ruta B de S2. Cada avance se entrega con `plantilla-avance.md` completada y se evalúa con `rubrica-avance.md`. Entrégalo en tu repositorio personal, con una rama por avance (`avance-1`, `avance-2`…), o en una carpeta comprimida si no hay repositorio.

10. Reglas

- **Cita la fuente** (la licencia la exige):
  - Moro, S., Rita, P., & Cortez, P. (2014). *Bank Marketing* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5K306
  - La documentación del autor pide además citar: S. Moro, P. Cortez y P. Rita, *A Data-Driven Approach to Predict the Success of Bank Telemarketing*, Decision Support Systems (2014), doi:10.1016/j.dss.2014.03.001.
  - Si cambias el dato (limpiar, renombrar), indícalo.

- No subas claves, tokens ni credenciales al repositorio.
- **No se evalúa solo con capturas**: entrega código, pruebas y pasos que otra persona pueda ejecutar.
- Declara lo que **no** pudiste ejecutar y el error exacto, y cita la ayuda que recibiste (personas y herramientas).

Antes de S1

- [ ] La huella de mi copia es correcta (`sha256sum -c SHA256SUMS`).
- [ ] El comando de lectura imprime `(41188, 21)`.
- [ ] He leído `bank-additional-names.txt` entera.
- [ ] Puedo explicar por qué `duration` queda fuera.
- [ ] Sé qué decisiones son mías (apartado 6) y qué se entrega en cada avance (apartado 9).

Documentos relacionados: `plantilla-avance.md` · `rubrica-avance.md` · presentación · datos