Tu caso: Bank Marketing

Es el caso que desarrollas tú **de S1 a S5**, con la misma receta que el docente usa con Online Retail II: **RAW → MASTER → FS → ML → entrenamiento**, y después API, contenedor, GCP y workflow. Esta hoja dice qué dato tienes, qué decisiones son tuyas y qué se entrega. Léela entera antes de S1. La presentación «Tu caso de S1 a S5» resume lo mismo en 12 diapositivas.

> **Aquí no hay un modelo de referencia que alcanzar.** Lo que se evalúa es tu razonamiento, tus pruebas y que otra persona pueda repetir tu trabajo (ver `rubrica-avance.md`).

1. La pregunta

Un banco portugués llamó por teléfono a sus clientes para venderles un **depósito a plazo**, de mayo de 2008 a noviembre de 2010.

> **Antes de llamar a un cliente, ¿contratará el depósito a plazo?**

- Cada fila es **una llamada**. No hay identificador de cliente: no puedes agrupar por cliente ni saber si dos filas son la misma persona.
- El objetivo es la columna `y`: `yes` (contrató) o `no`.
- Solo puedes usar lo que se sabe **antes** de que el cliente conteste. Por eso `duration` **(la duración de la llamada) queda fuera del modelo**: ver el apartado 5.

2. El dato

- Archivo: `02-Proyecto-Transversal/datos/bank-marketing/bank-additional-full.csv` (separador `;`).
- Documentación del autor: `02-Proyecto-Transversal/datos/bank-marketing/bank-additional-names.txt`. **Léela entera.**
- Licencia **CC BY 4.0**: puedes usarlo citando la fuente (apartado 9).

Desde la raíz del repositorio, con el entorno `env-ia-mlops` activo, este comando lee el archivo:

```
python -c "import pandas as pd; d = pd.read_csv('02-Proyecto-Transversal/datos/bank-marketing/bank-additional-full.csv', sep=';'); print(d.shape);
print(d['y'].value_counts().to_dict())"
```

Debe imprimir:

```
(41188, 21)
{'no': 36548, 'yes': 4640}
```

Para comprobar que tu copia es la original (desde la carpeta `02-Proyecto-Transversal/datos`; en PowerShell, `Get-FileHash -Algorithm SHA256 bank-marketing\bank-additional-full.csv` y compara con la línea de `SHA256SUMS`):

```
sha256sum -c SHA256SUMS
```

No hagas esto:

- Abrirlo y guardarlo con Excel: cambia el archivo.
- Reordenar las filas: **el orden del archivo es la única información temporal** que tienes (está ordenado por fecha) y la necesitarás en S5.
- Editarlo a mano. Todo cambio se hace con código, sobre la copia de tu capa RAW.

3. Cifras para comprobar tu carga

Medidas sobre el archivo del repositorio. **Tu RAW debe cuadrar con ellas**: si no, algo falló en tu carga. Tu MASTER cambia según tus decisiones (si descartas filas idénticas, ya no tendrás 41 188 filas): lo que siempre debe cuadrar es `raw = master + descartes`.

Qué	Valor
Filas · columnas	41 188 · 21 (20 variables + `y`)
`y` = `yes`	4 640 (11,27 %)
`y` = `no`	36 548
Filas idénticas a otra (en las 21 columnas)	12 pares
Valores `unknown`	`job` 330 · `marital` 80 · `education` 1 731 · `default` 8 597 · `housing` 990 · `loan` 990
`pdays` = 999	39 673 filas
`previous` > 0 y `pdays` = 999 a la vez	4 110 filas
`poutcome` = `nonexistent`	35 563 filas (son exactamente las de `previous` = 0)
Meses presentes	todos menos enero y febrero; no hay año ni fecha en ninguna columna

Con un 11,27 % de síes, un modelo que **siempre** dijera «no» acertaría el 88,73 % de las veces. Por eso se mira el AUC y la precisión media, no solo la exactitud.

4. Las variables, en cuatro grupos

La clasificación es la del autor. **Ojo** señala lo que tendrás que decidir.

Del cliente (7)

- `age`: edad. **Ojo:** en este archivo va de 17 a 98.
- `job`: tipo de trabajo (12 categorías). **Ojo:** tiene `unknown`.
- `marital`: estado civil. **Ojo:** `divorced` incluye viudos, según el autor; tiene `unknown`.
- `education`: nivel de estudios (8 categorías). **Ojo:** tiene `unknown`.
- `default`: ¿tiene crédito en mora? **Ojo:** solo 3 `yes`; 8 597 `unknown`. Además, `default` es una palabra reservada de SQL: en una tabla se escribe entre comillas (`"default"`) o se renombra.
- `housing`: ¿tiene crédito de vivienda? **Ojo:** tiene `unknown`.

- `loan`: ¿tiene préstamo personal? **Ojo:** tiene `unknown`.

Del último contacto (4)

- `contact`: tipo de contacto, `cellular` o `telephone`.
- `month`: mes del último contacto. **Ojo:** sin año.
- `day_of_week`: día de la semana (lunes a viernes).
- `duration`: duración de la llamada, en segundos. **Ojo: queda fuera del modelo.**

De campañas anteriores y de esta (4)

- `campaign`: contactos de esta campaña con este cliente. **Ojo:** incluye la llamada actual.
- `pdays`: días desde el último contacto de una campaña anterior. **Ojo:** 999 es un código, no días.
- `previous`: contactos antes de esta campaña.
- `poutcome`: resultado de la campaña anterior: `failure`, `nonexistent` o `success`.

Contexto económico (5) (indicadores del país publicados por el Banco de Portugal; no son del cliente)

- `emp.var.rate`: variación del empleo (trimestral).
- `cons.price.idx`: índice de precios al consumo (mensual).
- `cons.conf.idx`: índice de confianza del consumidor (mensual).
- `euribor3m`: euríbor a 3 meses (diaria).
- `nr.employed`: número de empleados (trimestral).

Objetivo: `y`.

5. La trampa: `duration`

`duration` es la duración de la llamada. **Solo se conoce cuando la llamada termina**, y una llamada larga suele ser una llamada que acaba bien: usarla es decirle al modelo lo que quieres que adivine. El propio autor lo advierte en `bank-additional-names.txt`: si la duración es 0, la respuesta es «no» (pasa en 4 filas de este archivo), y recomienda descartarla en un modelo realista.

Qué haces:

1. Déjala **fuera de FS y de ML**.
2. Escribe una **prueba** que falle si `duration` (o cualquier columna que no se conozca antes de llamar) vuelve a entrar en las variables del modelo. Es tu equivalente de la prueba «no futuro» del caso del docente.
3. Si algún día tu AUC te parece demasiado bueno, **sospecha de una fuga** antes de celebrarlo.

6. Decisiones que son tuyas

En cada una, deja escrito en tu avance qué hiciste, **por qué** y qué efecto tuvo (cuántas filas, cuánto cambian las métricas si lo pruebas).

Decisión	Lo que hay en el archivo	Preguntas
`unknown`	seis columnas (apartado 3)	¿Lo tratas como valor perdido, como una categoría más o descartas filas? ¿Es lo mismo en `default` (8 597) que en `marital` (80)? Si descartas filas, ya no evalúas sobre las mismas llamadas: piensa si puedes comparar las métricas con y sin ese descarte.
Filas idénticas	12 pares, iguales en las 21 columnas (también en `duration`)	Sin identificador de cliente no se sabe si es la misma llamada repetida o dos llamadas distintas con los mismos valores. ¿Qué haces? Lo descartado debe quedar en una tabla de descartes, con su motivo, para que `raw = master + descartes`.
`pdays` **= 999 y** `previous`	4 110 filas con `previous` > 0 y `pdays` = 999, aunque la documentación dice que 999 es «no contactado antes»	Un 999 tratado como días es un valor enorme que no significa lo que parece. ¿Cómo lo representas (por ejemplo, una variable «fue contactado antes» y los días solo cuando existen)? ¿Qué haces con esas 4 110 filas?
`campaign`	cuenta **incluida** la llamada actual	¿Lo conoces antes de marcar el número? Si la usas, explica en qué sentido.
Indicadores económicos	trimestrales, mensuales y diarios	¿Estaba publicado el valor cuando se hizo la llamada? ¿Qué pasa con ellos al partir los datos?
`month` **y** `day_of_week`	sin año ni fecha	¿Cómo los codificas? Con el año ausente, `month` mezcla campañas de años distintos.

7. Cómo se traduce a las capas

Parte de la estructura de `04-Proyecto-Base/` (mismas carpetas: `sql/`, `notebooks/`, paquete Python, `tests/`, `models/`, `reports/`; ver su `docs/modelo-de-datos.md`). Los nombres de tablas de la columna central son orientativos: si cambias alguno, sé coherente en todo el proyecto. Si copias `04-Proyecto-Base/` para empezar, cambia el nombre del paquete **y el** `name` **de su** `pyproject.toml`: si no, al instalar tu copia en el mismo entorno (`pip install -e .`) sustituye a la instalación del original y `import ia_mlops` carga la tuya (comprobado con `uv pip install -e`). En SQL, los nombres con punto (`"emp.var.rate"`) y `"default"` necesitan comillas dobles; MASTER los renombra para no arrastrar el problema.

Capa	Qué haces con Bank Marketing	Tablas (orientativas)	Qué compruebas
RAW	Cargas el CSV **tal cual**, sin limpiar, con el **número de fila original** y la huella del archivo	`raw_llamadas`, `raw_carga`	41 188 filas; 4 640 síes
MASTER	Tipos correctos, nombres de columna sin puntos (`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `nr.employed`), tus decisiones sobre `unknown`, duplicados y `pdays`; reglas de calidad	`master_llamadas`, `master_descartes`, `master_calidad`	`raw = master + descartes`; categorías dentro de lo que dice la documentación
FS	Una fila por llamada con las variables **conocidas antes de llamar**, y su catálogo (descripción, fórmula, unidad y por qué se conoce antes)	`fs_llamada`, `fs_catalogo`	`duration` no está; la prueba lo vigila

Capa	Qué haces con Bank Marketing	Tablas (orientativas)	Qué compruebas
ML	Objetivo (`y` a 1 y 0) y partición aleatoria estratificada, con semilla, guardada en una tabla	`ml_dataset`, `ml_particiones`	proporción de síes parecida en las tres particiones
Entrenamiento	Los tres modelos del caso del docente (referencia sin aprender, regresión logística y *gradient boosting*), con AUC y precisión media en validación y prueba, registrados en MLflow	`models/`, `reports/`	dos ejecuciones comparables; la elección se hace con validación

La **huella** de cada capa (cuántas filas y de dónde vienen) es lo que te permite decir «este modelo se entrenó con estos datos».

8. La partición

- **De S1 a S4: aleatoria y estratificada.** La misma proporción de síes en entrenamiento, validación y prueba, con una semilla fija y guardada. **Es optimista, y debes dejarlo escrito**: probablemente, porque las llamadas de una misma época se parecen y quedan repartidas entre entrenamiento y prueba. Una diferencia pequeña entre dos modelos o dos ejecuciones puede ser solo azar de la partición: si vas a decidir con ella, repite con otra semilla y anótalo.
- **En S5: el mismo modelo, evaluado por orden de filas** (las primeras para entrenar, las últimas para probar). Compara con lo anterior y explica la diferencia; empieza por mirar qué proporción de síes hay en cada tramo. No hace falta antes: si lo pruebas por tu cuenta, anótalo como exploración.

9. Qué se entrega y cuándo

Las sesiones son los **miércoles y viernes, de 10:00 a 14:00 (hora de Perú)**: S0 el miércoles 11 de noviembre, S1 el viernes 13, S2 el miércoles 18, S3 el viernes 20, S4 el miércoles 25 y S5 el viernes 27.

Cada avance se presenta en la **sesión siguiente** a aquella en la que se trabaja y se entrega **antes de que empiece: a las 10:00 (hora de Perú) de ese día**. Entre S1 y S2 y entre S3 y S4 hay cinco días; entre S2 y S3 y entre S4 y S5, solo dos, así que los avances 2 y 4 conviene empezarlos en cuanto termina la sesión. Se entrega rellenando el **formulario de Google del curso** (el instructor da el enlace en clase), una vez por avance: tu nombre, el número de avance, el enlace a tu rama o a tu carpeta comprimida y «qué no pude ejecutar». La hora de entrega es la que marca el formulario.

Avance	Se trabaja en	Se presenta en	Entrega, a más tardar	Qué lleva
1	S1 y trabajo autónomo	S2	mié 18 nov, 10:00	Capas RAW → MASTER → FS → ML, entrenamiento y métricas, **como cuadernos**
2	S2 y trabajo autónomo	S3	vie 20 nov, 10:00	El pipeline **ya en Python** (la traducción de los cuadernos), API, contenedor y pruebas. **La Ruta B de la tarea de S2 es este avance**
3	S3 y trabajo autónomo	S4	mié 25 nov, 10:00	Migración a GCP y despliegue: inventario, datos migrados y validados, servicio desplegado y registros. Opcional: módulo neuronal

Avance	Se trabaja en	Se presenta en	Entrega, a más tardar	Qué lleva
4	S4 y trabajo autónomo	S5	vie 27 nov, 10:00	Pipeline orquestado con GitHub Actions: workflow funcionando, historial de ejecuciones y una decisión explicada
Final	tras S5	por definir	vie 11 dic, 10:00	Repositorio, informe y demostración, con la evaluación por orden de filas de S5

Las tareas de cada sesión (por ejemplo, la de S1: añadir una variable al caso Online Retail II) son un ejercicio aparte de estos avances, salvo la Ruta B de S2. Cada avance se entrega con `plantilla-avance.md` completada y se evalúa con `rubrica-avance.md`. Entrégalo en tu repositorio personal, con una rama por avance (`avance-1`, `avance-2`…), o en una carpeta comprimida si no hay repositorio. Si tu repositorio es privado, añade al instructor como colaborador antes de entregar (su usuario lo indica en clase); si entregas una carpeta comprimida, súbela a tu nube y comparte el enlace con acceso para quien lo tenga. Para crear ramas y subirlas: `git-y-ramas.md`.

10. Reglas

- **Cita la fuente** (la licencia la exige):
  - Moro, S., Rita, P., & Cortez, P. (2014). *Bank Marketing* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5K306
  - La documentación del autor pide además citar: S. Moro, P. Cortez y P. Rita, *A Data-Driven Approach to Predict the Success of Bank Telemarketing*, Decision Support Systems (2014), doi:10.1016/j.dss.2014.03.001.
  - Si cambias el dato (limpiar, renombrar), indícalo.
- No subas claves, tokens ni credenciales al repositorio.
- **No se evalúa solo con capturas**: entrega código, pruebas y pasos que otra persona pueda ejecutar.
- Declara lo que **no** pudiste ejecutar y el error exacto, y cita la ayuda que recibiste (personas y herramientas).

Antes de S1

- [ ] La huella de mi copia es correcta (`sha256sum -c SHA256SUMS`).
- [ ] El comando de lectura imprime `(41188, 21)`.
- [ ] He leído `bank-additional-names.txt` entera.
- [ ] Puedo explicar por qué `duration` queda fuera.
- [ ] Sé qué decisiones son mías (apartado 6) y qué se entrega en cada avance (apartado 9).

Documentos relacionados: `plantilla-avance.md` · `rubrica-avance.md` · presentación · datos