S1 · De los datos al modelo (4 horas)

Caso transversal: **Online Retail II** → *¿volverá este cliente a comprar en los próximos 90 días?* Proyecto de trabajo: `04-Proyecto-Base/`.

Dos casos (presentados en S0): el del instructor, Online Retail II, es el de esta sesión y su tarea. El de los alumnos es **Bank Marketing** (`02-Proyecto-Transversal/datos/`): repiten la receta sobre él y lo presentan como **avance en S2**. Ver `02-Proyecto-Transversal/enunciado/README.md`.

Objetivo

Al terminar, la persona asistente puede:

1. Explicar y reconstruir las capas **OPERACIONAL** → **RAW** → **MASTER** → **FS** → **ML** con un cuaderno por capa.
2. Justificar por qué una variable no puede usar información posterior al corte y comprobarlo con una prueba.
3. Entrenar tres modelos con partición temporal, compararlos y registrar las ejecuciones en **MLflow**.
4. Traducir los cuadernos a Python y comprobar que el resultado es idéntico.

Agenda

Min	Bloque	Material
0–30	Revisión de entorno	`slides/` diap. 3 · `checklist.md`
30–90	Teoría	`slides/` diap. 4–16 · `teoria/README.md`
90–225	Práctica (135 min, pausa de 10)	`practica/guia-laboratorio.md`
225–240	Entrega y cierre (tarea y avance en Bank Marketing)	`tarea/README.md` · `slides/` diap. 18–20

Contenido de esta carpeta

- `index.html`: índice de la sesión (presentaciones, documentos y qué falta). Se genera con `00-Planificacion/indices-de-sesion/generar_indices.py`.
- `slides/index.html`: presentación interactiva (20 diapositivas; flechas, **O** índice, **S** notas, **F** pantalla completa).
- `guion.md`: guion del docente minuto a minuto.
- `checklist.md`: comprobaciones del docente y del alumnado.
- `teoria/README.md`: resumen de teoría y glosario.
- `practica/guia-laboratorio.md`: laboratorio paso a paso con presupuesto de tiempo.
- `tarea/README.md` y `tarea/rubrica.md`: tarea y rúbrica (20/40/40).
- `evidencias/plantilla-decision.md`: plantilla de la evidencia entregable.

- PDF de la presentación y de los documentos (los exige la institución): `pdfs/S1-Datos-y-Entrenamiento/` en la raíz del repositorio; ver `pdfs/LEEME.md`.

Qué está validado y qué no

- **Validado (Linux, entorno `env-ia-mlops`):** los cuatro cuadernos y el paquete `ia_mlops` con la muestra y con el dato completo (resultados idénticos), 34 pruebas en verde, y la receta de la tarea (añadir `monto_180d`: pipeline completo y 30 pruebas rápidas en verde).
- **Validado el 11/11/2026 (Windows 11, entorno `env-ia-mlops`), tras añadir el cuaderno 00 y la base operacional:** los cinco cuadernos y el paquete con la muestra y con el dato completo; MASTER, FS y ML idénticos a los de antes; 44 pruebas en verde (40 rápidas), con los cuatro pipelines independientes e idempotentes. La receta de `monto_180d` no se ha repetido con el flujo nuevo.
- **No validado:** una instalación limpia en Windows siguiendo la guía (ver `03-Entorno/PRUEBA-EN-WINDOWS.md`); la tarea con un dataset distinto (por decidir).
- **Cifras de las diapositivas:** las del dato completo salen de `04-Proyecto-Base` ejecutado sobre el Excel de UCI; con la **muestra** del curso (23 070 filas) los modelos dan valores menores (regresión logística: valid 0,698 · test 0,747). Es esperado.

MLflow en S1 (versión ligera)

Solo seguimiento: parámetros, métricas, firma del modelo y comparación de ejecuciones (`mlflow ui`). El registro de modelos y los alias llegan en S4 y S5. Con MLflow 3 el proyecto guarda el modelo con cloudpickle (ver `03-Entorno/VALIDACION.md`).