S1 · De los datos al modelo (4 horas)

Caso transversal: **Online Retail II** → *¿volverá este cliente a comprar en los próximos 90 días?* Proyecto de trabajo: `04-Proyecto-Base/`.

Dos casos (presentados en S0): el del instructor, Online Retail II, es el de esta sesión y su tarea. El de los alumnos es **Bank Marketing** (`02-Proyecto-Transversal/datos/`): repiten la receta sobre él y lo presentan como **avance en S2**. Ver `02-Proyecto-Transversal/enunciado/README.md`.

Objetivo

Al terminar, la persona asistente puede:

1. Explicar y reconstruir las capas **OPERACIONAL** → **RAW** → **MASTER** → **FS** → **ML** con un cuaderno por capa.
2. Justificar por qué una variable no puede usar información posterior al corte y comprobarlo con una prueba.
3. Entrenar tres modelos con partición temporal, compararlos y registrar las ejecuciones en **MLflow**.
4. Traducir los cuadernos a Python y comprobar que el resultado es idéntico.

Agenda

Min	Bloque	Material
0–30	Revisión de entorno	`slides/` diap. 3 · `checklist.md`
30–90	Teoría	`slides/` diap. 4–16 · `teoria/README.md`
90–225	Práctica (135 min, pausa de 10)	`practica/guia-laboratorio.md`
225–240	Entrega y cierre (tarea y avance en Bank Marketing)	`tarea/README.md` · `slides/` diap. 18–20

Contenido de esta carpeta

- `index.html`: índice de la sesión (presentaciones, documentos y qué falta). Se genera con `00-Planificacion/indices-de-sesion/generar_indices.py`.
- `slides/index.html`: presentación interactiva (20 diapositivas; flechas, **O** índice, **S** notas, **F** pantalla completa).
- `slides/caso-propio/index.html`: «Tu caso de S1 a S5», 12 diapositivas sobre el caso propio del alumnado (Bank Marketing). Se genera con `slides/caso-propio/generar.py`; 62 pruebas en `slides/caso-propio/pruebas/`. No está en la agenda de arriba: ver el punto 23 de `00-Planificacion/decisiones-y-pendientes.md`.
- Material del caso propio, en `02-Proyecto-Transversal/alumno/`: `tu-caso-bank-marketing.md` (hoja del alumno), `plantilla-avance.md` y `rubrica-avance.md` (20/40/40).
- `guion.md`: guion del docente minuto a minuto.

- `checklist.md`: comprobaciones del docente y del alumnado.
- `teoria/README.md`: resumen de teoría y glosario.
- `practica/guia-laboratorio.md`: laboratorio paso a paso con presupuesto de tiempo.
- `tarea/README.md` y `tarea/rubrica.md`: tarea y rúbrica (20/40/40).
- `evidencias/plantilla-decision.md`: plantilla de la evidencia entregable.
- PDF de la presentación y de los documentos (los exige la institución): `pdfs/S1-Datos-y-Entrenamiento/` en la raíz del repositorio; ver `pdfs/LEEME.md`.

Qué está validado y qué no

- **Validado (Linux, entorno `env-ia-mlops`):** los cuatro cuadernos y el paquete `ia_mlops` con la muestra y con el dato completo (resultados idénticos), 34 pruebas en verde, y la receta de la tarea (añadir `monto_180d`: pipeline completo y 30 pruebas rápidas en verde).
- **Validado el 11/11/2026 (Windows 11, entorno `env-ia-mlops`), tras añadir el cuaderno 00 y la base operacional:** los cinco cuadernos y el paquete con la muestra y con el dato completo; MASTER, FS y ML idénticos a los de antes; 44 pruebas en verde (40 rápidas), con los cuatro pipelines independientes e idempotentes; tras juntarlo con la API de S2, 123 (119 rápidas). La receta de `monto_180d` no se ha repetido con el flujo nuevo.
- **Validado el 13/11/2026 (Windows 11):** con el registro de modelos y `python -m ia_mlops.mlflow_ui`, 125 pruebas (121 rápidas y las 4 lentas que ejecutan los cuadernos); el pipeline registra la versión y la interfaz la muestra en *Model registry*. (Hoy son 131, 127 rápidas: se añadieron las 6 de la explotación del laboratorio extra de S2.)
- **No validado:** ejecución en Windows real (ver `03-Entorno/PRUEBA-EN-WINDOWS.md`); el caso propio (Bank Marketing) con un alumno real: la receta de RAW a entrenamiento sí se comprobó con una base de referencia del docente (fuera del repositorio público; punto 16 de `00-Planificacion/decisiones-y-pendientes.md`), pero nadie ha seguido la hoja sin ayuda, y el contenedor, GCP real, el workflow en GitHub y Windows siguen sin probarse con las reglas de la hoja (la API, la migración local y el entrenamiento sí, en el repositorio privado de práctica; punto 16).
- **Cifras de las diapositivas:** las del dato completo salen de `04-Proyecto-Base` ejecutado sobre el Excel de UCI; con la **muestra** del curso (23 070 filas) los modelos dan valores menores (regresión logística: valid 0,698 · test 0,747). Es esperado.

MLflow en S1 (versión ligera)

Seguimiento (parámetros, métricas, firma del modelo y comparación de ejecuciones) y **registro del modelo elegido** como `retencion-90d`, con una versión nueva en cada entrenamiento (añadido el 13/11/2026). La interfaz se abre con `python -m ia_mlops.mlflow_ui` desde `04-Proyecto-Base`; en la web hay que elegir **Model training**. Los alias de producción y el *rollback* llegan en S4 y S5.

Por qué no `mlflow ui --backend-store-uri sqlite:///models/mlflow.db` (lo que decían los materiales hasta el 13/11/2026): la ruta es relativa y, lanzada desde la raíz del repositorio (donde se abre la terminal de VS Code), MLflow crea allí una base vacía sin avisar. Es lo que pasó al preparar S1: la interfaz arrancaba sin ejecuciones ni modelos. Con MLflow 3 el proyecto guarda el modelo con cloudpickle (ver `03-Entorno/VALIDACION.md`).